

# ECN 7060, cours 11

William McCausland

2020-11-17

# Hypothèses sur un paramètre $\theta \in \Theta$

- ▶ Deux hypothèses sur  $\theta$  :
  - ▶ hypothèse nulle  $H_0, \theta \in \Theta_0$
  - ▶ hypothèse alternative  $H_1, \theta \in \Theta_0^c$
- ▶ Notes :
  - ▶ Les hypothèses viennent d'une question scientifique d'intérêt.
  - ▶ Il n'y a rien ici de classique ou de bayésien.
  - ▶ La spécification de  $\Theta_0$  devrait précéder la recherche d'un test et l'évaluation d'un test.
  - ▶ Il y a une asymétrie qui n'est pas explicite ici.
  - ▶ L'asymétrie est une question d'erreur : on favorise le control d'un type d'erreur.

# Tests

- ▶ Deux décisions (même notation pour les actions)
  - ▶  $a_0$ , ne pas rejeter  $H_0$
  - ▶  $a_1$ , rejeter  $H_0$
- ▶ Deux régions de l'espace échantillonal :
  - ▶ région critique (ou de rejet)  $R \subseteq \mathcal{X}$
  - ▶ région de non-rejet  $R^c$
- ▶ Notes :
  - ▶ Une règle de décision est un  $\delta: \mathcal{X} \rightarrow \{a_0, a_1\}$
  - ▶  $R = \{x: \delta(x) = a_1\}$ ,  $R^c = \{x: \delta(x) = a_0\}$ .
  - ▶ réduction de dimension, comme dans le cas d'estimation ponctuelle : il y a souvent une statistique  $W(X)$  scalaire tel que  $R$  ou  $R^c$  prend la forme  $\{x: W(x) \in [a, b]\}$ , des fois avec  $a = -\infty$  ou  $b = \infty$ .
  - ▶ attention : quand  $W(X)$  est un estimateur de  $\theta$ , il est facile de confondre une hypothèse avec une région ( $R$  ou  $R^c$ ).

# Optimalité par fonction de perte

- Une fonction de perte assez générale :

$$L(\theta, a_0) = \begin{cases} 0 & \theta \in \Theta_0 \\ c_{II} & \theta \in \Theta_0^c \end{cases}$$

$$L(\theta, a_1) = \begin{cases} c_I & \theta \in \Theta_0 \\ 0 & \theta \in \Theta_0^c \end{cases}$$

- Notes :
  - $c_I$  est le coût d'une erreur du type I,  $c_{II}$  le coût d'une erreur du type II
  - Avec cette généralité, on peut briser la symétrie des deux hypothèses : choisir  $c_I \neq c_{II}$ .

# Les fonctions de risque et de puissance

- Le risque  $R(\theta, \delta) = E_\theta[L(\theta, \delta(X))]$  est

$$R(\theta, \delta) = \begin{cases} 0 \cdot P_\theta(\delta(X) = a_0) + c_I \cdot P_\theta(\delta(X) = a_1), & \theta \in \Theta_0, \\ c_{II} \cdot P_\theta(\delta(X) = a_0) + 0 \cdot P_\theta(\delta(X) = a_1), & \theta \in \Theta_0^c. \end{cases}$$

- Cela motive la définition de la fonction de puissance :

$$\beta(\theta) \equiv P_\theta(X \in R) = P_\theta(\delta(X) = a_1)$$

- On peut écrire tout court

$$R(\theta, \delta) = \begin{cases} c_I \beta(\theta), & \theta \in \Theta_0, \\ c_{II}(1 - \beta(\theta)), & \theta \in \Theta_0^c \end{cases}$$

- Rappel : c'est une exercice *ex ante*.

## Risque de Bayes

- ▶ Rappel :  $r(\pi, \delta) = \int R(\theta, \delta) \pi(\theta) d\theta = E[E[L(\theta, \delta(X))|\theta]] = E[L(\theta, \delta(X))] = E[E[L(\theta, \delta(X))|X]]$ .
- ▶ Pour un échantillon  $x$  observé, la perte espérée *a posteriori* est

$$\begin{aligned} & E[L(\theta, \delta(X))|x] \\ &= \begin{cases} 0 \cdot P[\theta \in \Theta_0|x] + c_{II} \cdot P[\theta \in \Theta_0^c|x], & \delta(x) = a_0 \\ c_I \cdot P[\theta \in \Theta_0|x] + 0 \cdot P[\theta \in \Theta_0^c|x], & \delta(x) = a_1 \end{cases} \end{aligned}$$

- ▶ La solution  $\delta(x)$  qui minimise la perte *a posteriori* est

$$\delta(x) = \begin{cases} a_0, & \frac{c_I}{c_{II}} \frac{P[\theta \in \Theta_0|x]}{P[\theta \in \Theta_0^c|x]} \geq 1, \\ a_1, & \text{autrement.} \end{cases}$$

- ▶ Notes :
  - ▶ C'est une exercice *ex post*.
  - ▶ La distinction entre  $H_0$  et  $H_1$  est seulement en termes de  $c_{II}/c_I$ .

# Intuition Neyman Pearson I

- ▶ Supposons qu'il y a deux valeurs possibles de  $\theta$  :  $\theta_0$  et  $\theta_1$ .
- ▶ On divise  $\mathcal{X}$  en deux :  $R$  où  $\delta(x) = a_1$  et  $R^c$  où  $\delta(x) = a_0$ .
- ▶ On choisit  $R$  pour maximiser  $p(R|\theta_1)$  sous la contrainte  $p(R|\theta_0) \leq c$ .
- ▶ Une fonction de Lagrange pour ce problème :

$$P[R|\theta_1] - \lambda(P[R|\theta_0] - c).$$

- ▶ Pour  $x_2 \in \mathcal{X}$  à la frontière entre  $R$  optimal et  $R^c$  et un voisinage infinitesimal  $dR_2$  autour de  $x_2$ ,

$$P[R + dR_2|\theta_1] - P[R|\theta_1] - \lambda(P[R + dR_2|\theta_0] - P[R|\theta_0]) = 0.$$

ou

$$p(x_2|\theta_1) - \lambda p(x_2|\theta_0) = 0.$$

## Intuition Neyman Pearson II

- ▶ De la diapo précédente :

$$\frac{p(x_2|\theta_1)}{p(x_2|\theta_0)} = \lambda.$$

- ▶ Pour  $x_1 \in \mathcal{X}$  à l'intérieure de  $R$ ,


$$\frac{p(x_1|\theta_1)}{p(x_1|\theta_0)} > \lambda.$$

- ▶ Pour  $x_3 \in \mathcal{X}$  à l'intérieure de  $R^c$ ,

$$\frac{p(x_3|\theta_1)}{p(x_3|\theta_0)} < \lambda.$$



# Illustration pour l'intuition Neyman Pearson



## Exemple récurrent Bernoulli

► Rappel :

1.  $X_1, \dots, X_n \sim \text{iid Bn}(\theta)$ ,  $\theta \in [0, 1]$ .
2.  $L(\theta, x) = \theta^r (1 - \theta)^{(n-r)}$ , où  $r$  est le nombre de uns.
3.  $\hat{\theta}_{\text{EMV}} = \hat{\theta} = r/n$ .

- Considérons les hypothèses  $H_0 : \theta \geq 1/2$  et  $H_1 : \theta < 1/2$
- $\Theta_0 = [1/2, 1]$ ,  $\Theta = [0, 1]$ ,  $\Theta_0^c = [0, 1/2)$
- Calculer le rapport des vraisemblances

$$\sup_{\theta \in \Theta_0} L(\theta|x) = \begin{cases} L(\hat{\theta}|x) & \hat{\theta} \geq 1/2 \\ L(1/2|x) = \left(\frac{1}{2}\right)^n & \hat{\theta} < 1/2 \end{cases}$$

$$\sup_{\theta \in \Theta} L(\theta|x) = L(\hat{\theta}|x)$$

$$\lambda(x) = \begin{cases} 1, & r \geq n/2, \\ \frac{(n/2)^n}{r^r (n-r)^{n-r}}, & r < n/2. \end{cases}$$

- Une fonction de la statistique suffisante. En général, on peut utiliser  $f(t|\theta)$  directement, obtenir le même résultat.

## Les valeurs de $\lambda(x)$ pour $n = 12$

$r$	$\lambda(x)$	$P_{\theta}(R \leq r)$
0	0.000244	$(1 - \theta)^n$
1	0.007629	$(1 - \theta)^n + n\theta(1 - \theta)^{n-1}$
2	0.054420	$(1 - \theta)^n + n\theta(1 - \theta)^{n-1} + \binom{n}{2}\theta^2(1 - \theta)^{n-2}$
3	0.208098	...
4	0.506822	
5	0.845821	
6	1	
...	...	
12	1	1

# La forme d'un LRT

- ▶ La forme en général :

$$\left\{ x \in \mathcal{X} : \lambda(x) \equiv \frac{\sup_{\theta \in \Theta_0} L(\theta|x)}{\sup_{\theta \in \Theta} L(\theta|x)} \leq c \right\}$$

- ▶ Notes :

- ▶ attrait intuitive
- ▶ réduction de dimension

- ▶  $c \in [0, 1]$  à spécifier
- ▶ Ici, la forme d'un LRT est

$$\{x \in \mathcal{X} : \sum_i x_i \leq r\}, \quad r = 0, 1, 2, 3, 4, 5, 12$$


## Quelques fonctions de puissance $\beta_r(\theta)$

- Soit  $\beta_r(\theta)$  la fonction de puissance pour la région critique  $\{x: \sum_i x_i \leq r\}$

```
theta = seq(0, 1, by=0.01); n=12
beta_0 = pbinom(0, n, theta) # R = {r <= 0}
beta_1 = pbinom(1, n, theta) # R = {r <= 0}
beta_2 = pbinom(2, n, theta) # R = {r <= 2}
beta_3 = pbinom(3, n, theta)
beta_4 = pbinom(4, n, theta)
beta_5 = pbinom(5, n, theta)
beta_12 = pbinom(12, n, theta)
```

## Graphique des fonctions de puissance

```
plot(theta, beta_0, type='l'); lines(theta, beta_1)  
lines(theta, beta_2); lines(theta, beta_3)  
lines(theta, beta_4); lines(theta, beta_5); lines(theta, beta_6)
```



## Exemple, même modèle, hypothèse ponctuelle

- ▶ Considérons les hypothèses  $H_0 : \theta = 1/2$  et  $H_1 : \theta \neq 1/2$
- ▶ Ici, la LRT  $\lambda(x)$  est

$$\lambda(x) = \frac{(n/2)^n}{r^r (n-r)^{n-r}}.$$

Les valeurs de  $\lambda(x)$  pour  $n = 12$

	<u><math>r \quad \lambda(x)</math></u>
0	0.0002441406
1	0.0076294893
2	0.0544195584
3	0.2080983590
4	0.5068216324
5	0.8458214659
6	1.0000000000
7	0.8458214659
8	0.5068216324
9	0.2080983590
10	0.0544195584
11	0.0076294893
12	0.0002441406




## Quelques fonctions de puissance $\beta_r(\theta)$

- Soit  $\beta_c(\theta)$  la fonction de puissance pour la région critique  $\{x: |\sum_i x_i - n/2| \geq c\}$

```
theta = seq(0, 1, by=0.01); n=12
# R = {0,12}
beta_6 = pbinom(0, n, theta) + pbinom(0, n, 1-theta)
# R = {0,1,11,12}
beta_5 = pbinom(1, n, theta) + pbinom(1, n, 1-theta)
beta_4 = pbinom(2, n, theta) + pbinom(2, n, 1-theta)
beta_3 = pbinom(3, n, theta) + pbinom(3, n, 1-theta)
beta_2 = pbinom(4, n, theta) + pbinom(4, n, 1-theta)
# R = {0,1,2,3,4,5,7,8,9,10,11,12}
beta_1 = pbinom(5, n, theta) + pbinom(5, n, 1-theta)
```

## Graphique des fonctions de puissance

```
plot(theta, beta_6, type='l'); lines(theta, beta_5)  
lines(theta, beta_4); lines(theta, beta_3)  
lines(theta, beta_2); lines(theta, beta_1)
```



La probabilité *a posteriori*  $P(\theta \geq 1/2|x), r = 4$

- ▶ Soit  $n = 12$ ,  $\theta \sim \text{Be}(\alpha, \beta)$ , où  $\alpha = 1$ ,  $\beta = 1$ .
- ▶  $\theta|x \sim \text{Be}(\alpha + r, \beta + n - r)$
- ▶ Si on observe (mettons)  $r = 4$ ,  $\theta|x \sim \text{Be}(5, 9)$
- ▶  $P(\theta \geq 1/2|r(x) = 4) = 1 - F_{\text{Be}(5,9)}(1/2) = 0.1334229$ .

La probabilité *a posteriori*  $P(\theta \geq 1/2|x)$ , plusieurs  $r$

- Soit  $n = 12$ ,  $\alpha = 1$ ,  $\beta = 1$ ,  $\Omega_0 = [1/2, 1]$
- La probabilité *a posteriori* dépend du  $r$  observé :

$r$	$P[\theta \in \Omega_0  x]$
0	0.0001220703
1	0.0017089844
2	0.0112304688
3	0.0461425781
4	0.1334228516
5	0.2905273437
6	0.5000000000
7	0.7094726563
8	0.8665771484
9	0.9538574219
10	0.9887695312
11	0.9982910156
12	0.9998779297

# Test d'une hypothèse ponctuelle, une approche bayésienne

Un modèle composé, où le modèle  $M$ , le paramètre  $\theta$  et les données sont aléatoires :

$$f(M, \theta, x) = \Pr[M = H_0]1_{\{H_0\}}(M)\delta_{1/2}(\theta)(1/2)^n \\ + \Pr[M = H_1]1_{\{H_1\}}(M)f_{\text{Be}}(\theta; \alpha, \beta)\theta^r(1 - \theta)^{n-r}.$$

Après l'intégration de  $x$ ,

$$f(M, x) = \Pr[M = H_0]1_{\{H_0\}}(M)f_0(x) + \Pr[M = H_1]1_{\{H_1\}}(M)f_1(x),$$

où

$$f_0(x) = (1/2)^n, \quad f_1(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha + r)\Gamma(\beta + n - r)}{\Gamma(\alpha + \beta + n)}.$$

(cont.)

Les probabilités posterieures :

$$\Pr[M = H_0|x] = \frac{\Pr[M = H_0]f_0(x)}{\Pr[M = H_0]f_0(x) + \Pr[M = H_1]f_1(x)}$$

$$\Pr[M = H_1|x] = \frac{\Pr[M = H_1]f_1(x)}{\Pr[M = H_0]f_0(x) + \Pr[M = H_1]f_1(x)}$$

Le rapport de chances (rapport des cotes) postérieur :

$$\frac{\Pr[M = H_0|x]}{\Pr[M = H_1|x]} = \frac{\Pr[M = H_0]}{\Pr[M = H_1]} \frac{f_0(x)}{f_1(x)}$$

La décision optimale :

$$\delta(x) = \begin{cases} a_0 & \frac{c_I}{c_{II}} \frac{\Pr[M=H_0]}{\Pr[M=H_1]} \frac{f_0(x)}{f_1(x)} \geq 1, \\ a_1 & \text{autrement.} \end{cases}$$

# DID THE SUN JUST EXPLODE?

(IT'S NIGHT, SO WE'RE NOT SURE.)

THIS NEUTRINO DETECTOR MEASURES  
WHETHER THE SUN HAS GONE NOVA.

THEN, IT ROLLS TWO DICE. IF THEY  
BOTH COME UP SIX, IT LIES TO US.  
OTHERWISE, IT TELLS THE TRUTH.

LET'S TRY.

DETECTOR! HAS THE  
SUN GONE NOVA?

ROLL  
YES.



FREQUENTIST STATISTICIAN:

THE PROBABILITY OF THIS RESULT  
HAPPENING BY CHANCE IS  $\frac{1}{36} = 0.027$ .  
SINCE  $p < 0.05$ , I CONCLUDE  
THAT THE SUN HAS EXPLODED.



BAYESIAN STATISTICIAN:

BET YOU \$50  
IT HASN'T.

